AgentDesk 独立项目执行计划

企业工单排查与受控执行平台 | v1.0 | 2026-10-28 | 44 个有效学习周主线

目标：从会调用模型，练到能构建、诊断、评测和交付一个有权限边界、可恢复的 Agent 系统。

项目处理虚构 SaaS 产品的支持工单：查手册、查导出任务状态和日志，分析样本文件，提出带证据的解决方案；需要修改业务状态时，先展示具体操作，经过授权再执行，并留下审计记录。它与 MeetLoop 完全独立。

层次	必须交付
最小可用版本	单 Agent、只读工具、证据引用、失败退出、运行记录、离线测试集。
完整主线	检索权限、受控写操作、人工审批、代码沙箱、任务恢复、评测与灰度回退。
深入与求职	比较不同设计的实际效果，完成一次故障演练和两轮试用，能解释关键实现。
可选平台加深	模型网关、限流、队列、路由、vLLM 服务测量；不要求训练模型或写 CUDA 内核。

适合你的定位

主定位是 AI 应用 / Agent 工程，增加客户访谈、集成和交付可以支撑 FDE 方向。模型服务平台是后续分支，不与主线同时铺开。英语与沟通能力可以用于英文演示、需求澄清与方案讲解；技术可信度来自实际工程证据。

主线按约 400 小时估算。起步每周 7 小时，后续可增加到 8-10 小时，44 个有效学习周通常需要约 12-15 个日历月，基础补课和返工会延长。平台分支另计 80-120 小时。

“吃透”指能替换框架的一层、复现失败、证明修复和解释取舍，不以堆框架数量或无监督自主运行时长衡量。

具体产品与首版范围

用业务问题驱动技术学习，避免只做聊天界面

示例工单：“客户 A 的导出任务一直失败，请查原因，并给出处理建议。”系统读取工单、租户可见手册和任务日志；判断是临时依赖超时、权限不足还是 CSV 格式问题；给出证据和下一步。只有临时故障且满足策略时，才可申请重试导出。

输入情形	期望行为	如何确认结果
依赖临时超时	引用日志和运行手册；提出重试草案	审批后调用模拟业务 API；读取操作状态确认结果。
权限不足	说明缺少权限并交给负责人	绝不自行扩大角色或读取其他租户数据。
CSV 列缺失	在隔离环境分析样本并生成报告	输出缺列清单与文件哈希，不擅自修改原始文件。
手册过时 / 证据冲突	标记不确定，补查或请求人工处理	区分事实、推测和仍需核实的内容。
文档含伪造指令	把它当资料内容，继续按宿主策略执行	越权工具没有运行，拒绝原因进入审计。

首版只包含

- 一个工单入口、三个只读工具、结构化调查报告、20 个用例与运行日志。先做 CLI / API，控制台放到后面。
- 两个模拟租户、虚构文档和日志；用现成样例生成器或手工数据，不接真实客户系统。
- 暂不做浏览器全自动操作、即时通讯接入、自动发邮件、长期人格记忆、多个专家 Agent 团队。

先写规则化工作流作为基线。步骤固定且规则足够解决时，直接用代码；只有需要根据证据选择下一步时才引入模型决策。

技术栈与前置知识

以 Python 服务与工程机制为主；框架是一层可替换实现

层	默认选择	必须掌握
语言与 API	Python 3.12 或依赖支持的稳定版本；FastAPI / Pydantic	类型、异常、模块、asyncio、超时、取消、HTTP 与 JSON Schema。
运行时	先写小型循环，主项目使用 OpenAI Agents SDK	工具分发、停止条件、事件与会话；业务权限在 SDK 外单独执行。
数据	学习实验 SQLite；持久化阶段 PostgreSQL	SQL、索引、事务、约束、迁移、备份；pgvector 在检索基线之后按需增加。
前端	后期 TypeScript / React 简单控制台	运行列表、证据、审批与 SSE 事件流；不追加第二个 RN App。
验证与运维	pytest、结构化日志、容器与 CI	离线 Mock 回归、真实模型评测、追踪、故障复现与部署回滚。
沙箱	受限 Docker 起步；再评估 OpenSandbox	生命周期、隔离、出口网络、资源预算、产物回收；控制面与执行面分离。

先懂这些模型概念即可

token 与上下文窗口、概率输出与不确定性、结构化输出和工具调用、embedding 与相似度、检索与生成的区别、prefill / decode / KV cache 的概念。通过小实验解释现象；暂不要求反向传播推导、模型训练或论文产出。

课程优先用 Python 官方教程、FastAPI、Hugging Face Agents Course 的基础概念。只选一套实现主线；LangChain / LangGraph 可以比较，但不是前置条件，也不与 SDK 同时叠加。

Python 官方教程 / FastAPI Tutorial

Hugging Face Agents Course / OpenAI Agents SDK 源码

架构与信任边界

模型负责提出行动；宿主系统决定允许什么、如何执行、如何确认结果

用户 / 控制台 → API 与身份 → Run 管理器 → Agent 循环
Agent 循环 → 工具策略与审批 → 只读连接器 / 隔离执行器
事件、审批、工具回执 → 持久化与审计 → 评测与监控

组件	责任	明确边界
身份 / API	确认用户、租户、角色、请求预算	从登录上下文获取，不能信任模型给出的 tenant_id。
Run 管理器	创建运行、排队、取消、恢复与并发控制	持久化状态是事实来源，聊天历史不代替执行账本。
Agent 循环	选择工具、整合证据、形成建议	不能直接持有管理员凭据，也不能绕过工具策略。
工具网关	参数校验、资源授权、审批和幂等	执行前重查权限；所有调用都留下关联 ID 和结果。
隔离执行器	只在单次任务工作区运行代码 / 分析文件	不挂载用户主目录、宿主 Docker socket 或 API 密钥。
存储 / 观测	工单、文档、事件、回执、产物、评测版本	租户范围贯穿数据库查询、检索、缓存、日志与产物访问。

逐步创建目录

apps/api、apps/console、agent/runtime、agent/tools、agent/policy、agent/retrieval、worker、evals、fixtures、docs。第一阶段只建实际使用的部分；不提前写通用插件市场或分布式编排系统。

产品中的文档、工单、日志与工具输出都是数据来源，不能自动升级为系统指令。系统边界由代码和运行环境执行。

先亲手做一次 Agent 循环

第 5-10 周 | 不从框架 API 名称开始理解 Agent

做一个小型教学实现：组装上下文 → 请求模型 → 解析结构化行动 → 校验参数与权限 → 调用工具 → 记录事件 → 返回工具结果 → 继续或终止。先使用 scripted Mock 模型，之后再接一个真实模型适配器。

机制	需要完成的实验
停止与预算	最大轮数、总耗时、工具超时、输入 / 输出预算；检测重复无效调用；触发上限时给出部分结果和原因。
工具错误	区分参数错误、无权限、空结果、限流、超时和未知执行结果；不能全部转成“没有找到”。
状态	created → running → waiting_approval / succeeded / failed / cancelled；queued 在多任务阶段加入，恢复需重新校验。
上下文	保留目标、约束、已确认事实与证据 ID；大日志保存为产物，只回传摘要和受控读取入口。
取消	用户停止后不再发起新工具；取消传播到请求 / 执行器；已经发生的副作用需要对账，不能宣称撤销。
可替换性	相同 tools / policy / evals 接口换成 SDK 运行；比较行为差异，教学循环保留为理解和回归参考。

harness 到底包含什么

它是围绕模型的执行环境：工具与状态、上下文组装、预算、身份、权限、工作区、持久化、审批、恢复和观测。不是一个 prompt，也不是一次 while 循环。第一版就建立事件与预算，后续逐项强化。

OpenAI Agents SDK 源码 / Anthropic 长任务 harness 设计

字节 DeerFlow

工具设计与 MCP

先做强类型本地工具，再把一个只读工具暴露为 MCP

工具	权限与副作用	输出契约
get_ticket	读取当前租户的指定工单	工单字段、版本、来源 ID；不存在与无权的返回策略要一致。
search_docs	检索前过滤文档 ACL	片段、文档 / 版本 / chunk ID、时间与来源。
query_job_events	按 job_id 查询允许的日志	结构化事件、时间范围、截断标志；不用任意 SQL 接口。
analyze_csv	仅在沙箱读取上传样本	列 / 行统计、错误明细、输出产物；限制体积与资源。
draft_reply	保存当前任务范围的草稿	草稿 ID 与版本；明确没有发送。
retry_export	修改模拟业务状态，需策略通过与审批	operation_id、幂等键、状态；超时后查询回执。

每个工具固定名称、说明、输入 schema、输出 schema、错误类别、超时、权限与副作用等级。工具描述帮助模型选择；服务器仍须执行每项校验。禁止把任意 shell、任意 SQL、任意 URL 作为首版默认工具。

MCP 的验收

- 把 search_docs 做成 MCP server，客户端仍走相同策略；说明工具发现、schema、传输与身份之间的关系。
- 本地 stdio 从可信启动配置获得执行范围；远程 HTTP 按协议实现身份与令牌受众校验，避免把下游令牌直接透传。
- 模拟工具描述被改、服务不可用、超时和恶意返回内容；MCP 接入不自动等于可信授权。

MCP 安全实践 / AgentScope

检索与上下文工程

第 11-16 周 | 先证明检索有用，再增加复杂度

顺序	实现	对照验证
关键词基线	小文档集、稳定文档 ID 与版本、关键词 / 全文检索	先用人工问题集测能否找到正确证据。
向量与混合检索	比较 chunk 划分、embedding、关键词 + 向量	固定数据集测 recall@k 与最终任务成功率。
重排与引用	需要时才加 rerank；答案关联证据	检索分数不是答案置信度；检查引用是否支持具体结论。
权限与更新	检索前过滤租户与 ACL；文档删除 / 撤权使缓存失效	跨租户文档不能进入模型上下文或缓存结果。
长上下文	大输出落盘；摘要保留来源、未完成项、约束	比较全量、截断、摘要三种方式的成本与遗漏。

把“找不到证据”“证据冲突”“证据过时”作为正常结果。可以继续查询、请求补充或移交人工；不能为了完成任务编造事实。模型看到的材料只包含完成当前任务所需的信息。

记忆的边界

会话历史、任务状态和长期记忆是三回事。首版只保存任务状态与受控历史；长期偏好记忆作为可选实验，要求用户确认、可查改删、按租户隔离，并且不存凭据。权限判断不依赖记忆或摘要。

选 10 个失败样例，逐个区分：数据缺失、检索失败、引用不支持、模型推理错误，还是工具执行失败。不同问题要用不同修复。

腾讯 WeKnora / 字节 DeerFlow

Google ADK Python

权限与人工审批

第 1 版就限制只读；增加写操作前必须完成本页

动作	默认策略	执行位置
查询工单 / 文档	当前租户、当前用户可见资源	API / 数据层 / 检索层共同校验。
沙箱分析文件	只读输入与本任务输出目录	工具网关与隔离运行时；文件路径规范化并防越界。
保存回复草稿	当前工单内的草稿写入	权限校验、版本检查、审计。
重试导出任务	角色允许、任务可重试、次数受限、审批有效	执行前重新校验；审批不能扩大原角色权限。
跨租户访问 / 提权	禁止	确定性策略直接拒绝；不交给 LLM 自己决定。

审批对象必须具体

审批记录绑定 user_id、tenant_id、run_id、tool_call_id、工具与参数哈希、资源版本、策略版本、有效期和审批人。展示将修改什么、影响范围与预期结果；改参数、换资源、过期或权限撤回后需要重新确认。

至少验证六种失败

- 伪造 tenant_id；未授权角色；审批后修改参数；重复使用审批；审批等待期间撤权；资源版本变化。
- 每次拒绝记录策略原因；敏感参数先脱敏。不要把“用户曾批准这个工具”当成所有后续参数都获批。

Prompt 中写“不要越权”是辅助约束。实际权限边界必须位于模型之外，并覆盖检索、缓存、工具调用、文件与日志。

Agents SDK 人工审批与继续运行 / MCP 安全实践

AgentScope

沙箱与受控执行

第 17-24 周 | 没有隔离与策略，不开放模型生成代码

先执行你写好的 CSV 分析程序，理解文件传入、限制、取消和产物取回；再允许模型生成受限分析脚本。业务写入依旧走工具网关，沙箱没有业务系统的写凭据。

边界	学习项目基线
工作区	每个 run / trial 独立目录；输入只读，输出限额；路径和符号链接都验证，拒绝逃逸。
进程与权限	容器内非 root、只读根文件系统、删除多余 capabilities、禁止提权；不暴露宿主 socket。
资源	CPU、内存、进程数、执行时间、输出字节和磁盘上限；超时终止并回收，持续检查孤儿任务。
网络	默认禁止出网；确需访问时通过受控代理白名单；限制重定向与私网 / 元数据地址。
密钥与控制面	模型 API 在宿主服务侧；执行器不给主目录和密钥；沙箱管理接口只允许可信服务访问。
生命周期	创建、健康检查、运行、取消、取回产物、销毁；不确定状态先隔离，不直接复用给其他租户。

Docker 是学习基线，不等于对任意恶意代码的完整强隔离。主线只接自己构造的样例；若未来开放不可信代码，应在独立 Linux 节点评估 gVisor / microVM 等边界，补威胁建模与运维验证。

沙箱关卡

用无破坏的测试验证越界文件读取、未授权网络、持续循环、过量输出和任务取消；检查宿主未收到敏感数据、资源已释放，下一次任务无法看到上一租户的文件。

Docker Engine 安全边界 / OpenSandbox 当前仓库

OpenSandbox 文档

持久化、恢复与并发

第 25-32 周 | 聊天记录与数据库事务都不能自动保证外部动作只执行一次

记录	关键字段与作用
runs / run_events	租户、状态、版本、事件序号、预算、时间；事件追加写，状态按合法转换更新。
tool_calls / receipts	调用 ID、参数哈希、幂等键、attempt、执行状态、外部操作 ID；查询未知结果。
approvals	审批对象、范围、有效期与版本；恢复后再检查，不因重放自动扩大授权。
artifacts / documents	文件哈希、拥有者、租户、保留期限、版本与来源；独立做访问校验。
eval_runs	代码、prompt、模型、数据、策略版本，及每次 trial 的指标与轨迹。

五个必须做的故障实验

- 写入外部动作成功、回执丢失：进入 unknown / reconciling，通过 operation_id 查询，禁止盲目重试。
- worker 在调用前或调用后退出：重启读取检查点；用幂等键和回执判断是否继续。
- 两个 worker 抢同一任务：数据库租约、版本条件更新或锁防止并发处理；过期 worker 用 fencing / 版本拒绝。
- 用户取消与工具完成同时发生：取消只阻止后续动作；已发生副作用记录并展示真实结果。
- SSE 断连重连：按事件序号恢复展示，不因浏览器刷新重新启动整个业务动作。

先单进程 + SQLite 学状态，再用 PostgreSQL 验证并发与事务；需要多 worker 后再加可靠队列。明确投递、执行、回执各自的语义，不对外部系统宣称天然 exactly-once。

Microsoft Agent Framework / Google ADK Python

Agents SDK 人工审批与继续运行

从第一天建立评测

测任务结果、过程约束与成本，不能只看回答是否像样

维度	如何评分	常见误区
任务成功	检查报告字段、证据与模拟业务系统最终状态	Agent 说“已处理”不代表操作发生。
工具与权限	检查调用是否合法、是否越权或重复副作用	不强制只有一条固定推理路径。
证据正确	引用存在、版本一致、支持相关结论	有引用不等于引用有效。
可靠性	超时、取消、重启与限流后能否正确结束 / 恢复	不能把未知执行结果计为成功。
效率	成功任务总费用、端到端延迟、工具次数与 token	只比较 token 省多少可能掩盖成功率下降。

数据集递进

W1-4 先定义 10-20 个场景；W5-10 做 20 个可重复用例；W11-24 扩到约 60 个，覆盖权限 / 注入 / 异常；W25 后争取 100 个，并按场景族划分开发集与留出集，避免同题改写泄漏。数量是目标，不是当前已有成果。

确定性断言优先：数据库状态、权限拒绝、输出结构、引用 ID。LLM judge 只辅助评价解释质量，先用人工样本校准，记录模型版本与分歧。每次评测重置隔离环境；冻结用例，不根据失败偷偷修改标准。

离线 Mock 回归每次提交可跑；真实模型评测按预算选关键集并多次运行，报告 n、成功次数和失败类型。安全硬门槛要求测试集中没有越权，不代表证明绝对安全。

Anthropic Agent 评测方法 / pytest 入门

评测门槛与优化实验

第 33-38 周 | 用同一组任务比较，而不是凭演示效果选择设计

比较	保持固定	记录结果
规则工作流 vs 单 Agent	数据、工具权限与任务预算	任务成功率、无法处理比例与维护复杂度。
关键词 vs 混合检索	文档版本、问题与权限	召回、引用支持率、最终任务成功率。
完整上下文 vs 压缩	任务、输入资料与模型	遗漏约束、关键证据丢失、费用与延迟。
串行 vs 有限并行	仅独立、只读工具可并行	延迟、限流、取消与日志可解释性。
单模型 vs 路由	同样本与硬性策略	质量损失、失败回退、成功任务实际成本。

项目自定发布门槛

学习版建议：所有确定性权限 / 幂等 / 恢复回归通过；在冻结的核心留出集上，任务成功率目标先设 80%，每例至少 3 次，公开失败项与样本数。小数据集会有较大波动，不能当生产 SLA 或市场效果。

每次只改一类变量。保存基线、配置与原始记录；报告延迟中位数和 p95，同时提供样本量。成本按实际输入 / 输出计费和工具费用求和，价格未知就分开报告 token 与外部支出。

什么时候才加多 Agent

主线稳定后，用一个 2 周实验验证“检索助手 + 主 Agent”是否有明确收益；比较单 Agent 与固定工作流。如果更贵、更慢而成功率无提升，就删除。需要独立权限、预算、上下文与取消传播，不能靠角色名称宣称隔离。

Anthropic Agent 评测方法 / 字节 DeerFlow

部署、观测与实际交付

上线准备从可重复部署开始；FDE 的价值在于让系统进入真实流程

能力	项目中的交付
可重复环境	依赖锁定、数据库迁移、配置样例、虚构 seed 数据；本地一条文档化流程启动。
可观测性	run / tool / provider trace，脱敏日志、耗时、token、失败原因、队列长度与审批等待；不依赖保存隐藏推理。
故障处理	模型限流 / 超时熔断与有限重试；工具故障告警、运行暂停 / 人工接管；写回滚与恢复手册。
版本发布	prompt、策略、工具 schema、模型配置和数据索引分别版本化；候选版本跑回归，再做小范围试用。
数据管理	最少采集、日志脱敏、凭据外置、删除与备份恢复；调试记录不能泄漏租户内容。
用户体验	运行状态、证据可查看、失败原因、待审批动作与最终回执；取消后展示实际状态。

两轮试用，每轮 2-3 位同学

让试用者扮演支持人员完成固定任务，记录耗时、人工更正、误导和审批理解情况。先观察再提问；第二轮验证修复。用自己的模拟数据，不声称真实企业上线或虚构商业收益。

FDE 交付材料

一页需求与成功标准、业务流程图、数据和权限映射、接入契约、验收计划、运行手册、5 分钟英文演示。再模拟客户临时更改权限或字段，评估影响并交付修改。

Microsoft Agent Framework / 腾讯 WeKnora

44 周主线与阶段关卡

约 400 小时；关卡未通过就补实验，周数按有效学习周累计

阶段 / 估时	主要产出	进入下一阶段的证据
W1-4 / 32h	Python、HTTP、SQL、pytest；工单样例与确定性工作流	不依赖 AI 整段生成，能读写 JSON、查询数据、处理异常。
W5-10 / 48h	教学循环、只读工具、预算、日志；再接 SDK	20 例回归；能解释每次调用与停止原因，替换运行时。
W11-16 / 56h	检索、引用、租户过滤、上下文与 MCP 小实验	有检索基线和失败分析；跨租户证据不进入上下文。
W17-24 / 72h	审批、受控写入、沙箱与攻击样例	六类审批失败与沙箱边界测试通过；代码执行可取消回收。
W25-32 / 72h	PostgreSQL、恢复、幂等、多任务、控制台与观测	重启、回执丢失、重复任务、SSE 重连均能正确处理。
W33-38 / 60h	冻结评测、性能 / 成本实验、有限并行 / 路由	有基线与对照数据，能解释改进和退化；不盲目多 Agent。
W39-44 / 60h	部署、两轮试用、故障演练、文档与英文演示	他人能复现；现场改需求；能讲清三项工程取舍。

合计 400h。7h/周需要约 57 周；随着熟练度提高到 8-10h/周，约 40-50 周，加上学校与实习间断，按 12-15 个月安排更稳妥。44 周是工作包，不是要求每周都固定投入同样时长。

初始每周：MeetLoop 11h + AgentDesk 7h + 公共基础与复盘 3h。额外时间优先补故障实验、源码追踪和独立改题，不额外开启训练模型或另一个框架项目。

前四周与第一天怎么开始

可以在 Windows 开始；主线不依赖本地 GPU

周次	Agent 时间内完成	产出与过关
第 1 周	Python 基础、虚拟环境、Git；读 tickets.json；按租户过滤；看 5 个样例问题。	独立实现查询函数；不存在、无权与空结果有明确行为。
第 2 周	异常与类型、pytest、HTTP / JSON；FastAPI 两个只读接口；参数校验。	用测试验证正常与错误；能解释客户端请求到函数的路径。
第 3 周	SQLite、基础 SQL、日志；模拟工单调查的固定工作流；认识 token / tool calling。	不调用模型也能完成一条调查，明确哪些步骤需要模型判断。
第 4 周	定义工具 schema、10-20 个 eval 场景、运行事件；给自己做一次需求变更。	改字段不破坏旧用例；写清 W5 模型循环的输入、输出和终止条件。

第一天 2 小时

- 20 分钟：读本计划前 4 页，选一条“导出失败”工单，写出人如何调查。
- 25 分钟：打开 Python 教程，配置隔离环境或使用已有环境；只练列表、字典与函数。
- 50 分钟：读准备包里的 tickets.json，编写按 tenant_id + ticket_id 查询的函数，验证成功和拒绝两种情况。
- 25 分钟：不用 AI 解释一次数据流，记录两个卡点；给明天留下一个小任务。

准备包提供的是虚构数据、评测规格和策略示例，不是已实现的安全系统。第一天不需要购买 API、部署云服务或安装七个 Agent 框架。

Python 官方教程 / FastAPI Tutorial

pytest 入门 / Hugging Face Agents Course

从大厂开源项目学什么

截至 2026-10-28 核对官方仓库；以下是机制借鉴，不是安全审计或整套依赖清单

来源	借鉴机制	迁移为自己的任务
OpenAI Agents SDK	Runner、工具、会话、人工审批与 tracing	主 SDK；用相同业务工具替换教学循环，追一条完整调用链。
Google ADK	工作流、状态、工具确认与评测入口	对照固定流程与模型决策；学习事件和状态分离。
Microsoft Agent Framework	checkpoint、恢复、人工介入、OpenTelemetry	参考长任务恢复与可观测性，做 worker 重启实验。
字节 DeerFlow	skills、文件工作区、上下文压缩与 sandbox harness	学习大输出落盘、工作区与任务进展管理，不复制整个产品。
AgentScope	ReAct、工具管理、事件、中断 / 恢复、权限	比较如何中断工具循环以及恢复；实现自己的取消传播。
腾讯 WeKnora	检索、知识库、租户权限、引用与审计	借鉴企业数据链路，重点检查文档权限与检索更新。
OpenSandbox	统一生命周期、执行接口、出口策略与凭据边界	后续替换自建 runner，测创建 / 取消 / 回收与边界。

DeerFlow 自身使用 LangGraph / LangChain；可以研究它的 harness 设计，而不把这套栈全部引入 AgentDesk。原 alibaba/OpenSandbox 地址已重定向至 opensandbox-group/OpenSandbox，当前官网标注为 AAIF 项目；采用当前仓库链接。

OpenAI Agents SDK 源码 / Google ADK Python

Microsoft Agent Framework / 字节 DeerFlow

AgentScope / 腾讯 WeKnora

OpenSandbox 当前仓库

源码阅读与课程怎样配合

每次只追一个机制，用实验把阅读变成理解

阶段	阅读入口	读完要回答 / 实现
基础期	Python 教程、FastAPI Tutorial、pytest 入门	数据与异常怎样传播？写工单接口和边界测试。
循环期	HF Agents Course 基础；Agents SDK README 的 examples / Tools / Running	谁调用模型，谁执行工具，谁停止？画调用链并替换 Mock。
状态期	Google ADK Workflow / Tool Confirmation；MAF python/samples/03-workflows	状态保存在哪里？重启后如何继续且不重复动作？
上下文期	DeerFlow README 的 Context Engineering；Anthropic harness 文章	哪些内容摘要、哪些落盘？丢失关键信息会怎么失败？
权限期	AgentScope Permission & HITL；MCP Security Best Practices	谁拥有授权依据？尝试绕过描述层，验证宿主仍拒绝。
沙箱期	Docker security；OpenSandbox specs / docs	文件、进程和网络隔离分别在哪里生效？如何证明回收？
评测期	Anthropic Demystifying evals；自己的 eval runner	评分器验证结果还是只看文本？重跑差异如何报告？

阅读顺序：跑最小示例 → 从入口跟踪一次调用 → 找对应测试 → 改一个边界条件 → 写 200 字解释。记录仓库、commit SHA、所读文件 / 符号与日期；不用从头到尾读全仓库。

学习资料的目标是消除当前卡点。你能独立改行为并验证之后，再看下一个机制，不把收藏链接数量当成进度。

Python 官方教程 / FastAPI Tutorial

pytest 入门 / Hugging Face Agents Course

Anthropic 长任务 harness 设计 / Anthropic Agent 评测方法

模型服务平台的深入分支

主线通过后另用 8-12 个学习周，约 80-120 小时；无需重做业务产品

模块	具体实验	交付证据
模型网关	统一 provider 适配、超时、限流、配额、预算与密钥隔离	用 Mock provider 注入 429 / 超时 / 坏输出；并发下预算不被绕过。
排队与容量	有界队列、背压、公平调度、取消和优先级	负载增大时看队列等待与失败；验证取消请求不继续浪费资源。
vLLM 服务	在兼容的 Linux / GPU 环境提供模型；记录模型、硬件与请求分布	测 TTFT、逐 token 延迟、吞吐、排队、显存 / KV cache；不照抄他人数字。
路由与缓存	在质量门槛下比较小模型 / 强模型与缓存	按租户、权限与版本隔离缓存；记录命中、费用与质量变化。
运维与发布	健康检查、过载保护、配置版本、灰度 / 回滚与容量报告	模型故障能降级或明确失败；发布后评测不退化。

在 Windows / Mac 上先完成 API、队列、Mock 故障与容器实验。CUDA / GPU 服务另用兼容设备或短期远程环境；不能因为 Mac 内存足够就假定具备 CUDA。先估算用量和费用，再决定是否开启付费实验。

岗位方向的能力差别

Agent 工程侧重任务与可靠性；FDE 增加客户流程、系统集成和交付；模型平台增加 Linux、网络、并发、容量与性能。这三者共享后端基础，但深度不同。该分支不等于 GPU 内核、分布式训练或算法研究能力。

vLLM 服务指标 / OpenSandbox 文档

最终验收与求职展示

每项都要能现场解释、修改、制造失败并验证

关卡	现场挑战
不用框架也能解释	用教学循环讲一次工具执行全过程；换 SDK 时说明哪些代码不变。
权限实际生效	给工单塞入伪造指令，换租户 ID，篡改审批参数；所有越权动作必须被宿主拦住。
任务能恢复	运行中停止 worker，模拟写入成功但回执丢失；恢复后查询事实，不重复副作用。
结果可以测量	他人用固定数据和命令复现评测；解释失败分类、模型差异、成本与样本局限。
能交付需求变化	增加一个受限工具或变更角色规则；更新契约、策略和测试，完成演示。

留下三类工程案例

- 权限 / 沙箱案例：威胁、边界、失败样例与回归；不要把未发生事故当作安全证明。
- 恢复 / 幂等案例：时间线、状态、未知结果与对账，解释为什么不能简单重试。
- 评测 / 优化案例：基线、变量、原始数据与代价；如果优化没有收益，也说明结论和取舍。

项目可支撑 AI 应用、Agent 工程及部分 FDE / 平台岗位的作品展示，但岗位录用还涉及基础面试、协作、实际经历与地区资格。本计划不承诺就业，也不把模拟项目描述成真实客户系统。

最终标准：你可以不借助 AI 整段代写，独立交付边界明确的需求，并且对模型输出不稳定时系统的行为负责。

参考资料与版本维护

官方仓库与文档为主 | 链接核对日期 2026-10-28

OpenAI Agents SDK 源码 / Agents SDK 人工审批与继续运行

Google ADK Python / Microsoft Agent Framework

字节 DeerFlow / AgentScope

腾讯 WeKnora / OpenSandbox 当前仓库

OpenSandbox 文档 / Anthropic 长任务 harness 设计

Anthropic Agent 评测方法 / MCP 安全实践

Docker Engine 安全边界 / vLLM 服务指标

怎样防止资料过时

开始某个阶段时记录当前稳定版本、依赖锁文件和源码 commit。示例 API、默认权限与部署参数可能变化；先在隔离实验里跑通，再迁移到项目。这里借鉴的是机制，不承诺某个框架未来两年不变。

OpenAI 官方公告显示，旧 Evals 平台将于 2026-10-31 进入只读，并计划于 2026-11-30 关闭；Agent Builder 也计划于 2026-11-30 关闭。因此本项目把评测数据、执行器与断言保存在自己的仓库，不依赖这两项旧平台。

OpenAI API 弃用公告

本次交付的边界

已完成计划、学习入口、虚构数据、12 个评测规格样例、策略设计示例与来源清单。没有实现 Agent 应用、部署沙箱或跑真实模型评测；所有功能与指标均是接下来要做的目标。